多交互图卷积网络用于方面情感分析

王汝言* 陶中原 赵容剑 张普宁 杨志刚

(重庆邮电大学 通信与信息工程学院 重庆 400065)

(先进网络与智能互联技术重庆市高校重点实验室 重庆 400065)

(泛在感知与互联重庆市重点实验室 重庆 400065)

摘 要：方面情感分析旨在识别句子中特定方面的情感极性，是一项细粒度情感分析任务。传统基于注意力机制方法，仅在单词之间进行单一的语义交互，没有建立方面词与文本词的语法信息交互，导致方面词错误地关注到与其语法无关的文本词信息。此外，单词的位置距离特征和语法距离特征，分别体现其在句子线性形式中和句子语法依存树中的位置关系，而基于图卷积网络处理语法信息的方法却忽略距离特征，使距方面词较远的无关信息对其情感分析造成干扰。针对上述问题，该文提出多交互图卷积网络(MIGCN)，首先将文本词位置距离特征馈入到每层图卷积网络，同时利用依存树中文本词的语法距离特征对图卷积网络的邻接矩阵加权，最后，设计语义交互和语法交互分别处理单词之间语义和语法信息。实验结果表明，在公共数据集上，准确率和宏F1值均优于基准模型。

关键词：方面情感分析；图卷积网络；依存树；注意力机制

中图分类号：TP391.1 **文献标识码**：A **文章编号**：1009-5896(2022)03-1111-08

DOI: 10.11999/JEIT210459

Multi-interaction Graph Convolutional Networks for Aspect-level Sentiment Analysis

WANG Ruyan TAO Zhongyuan ZHAO Rongjian

ZHANG Puning YANG Zhigang

(*School of Communication and Information Engineering, Chongqing University of Posts and Telecommunications, Chongqing* 400065, *China*)

(*Advanced Network and Intelligent Connection Technology Key Laboratory of Chongqing Education Commission of China, Chongqing* 400065, *China*)

(*Chongqing Key Laboratory of Ubiquitous Sensing and Networking, Chongqing* 400065, *China*)

Abstract: Aspect level sentiment analysis aims to identify the sentiment polarity of a specific aspect in a given context, and is a fine-grained sentiment analysis task. The traditional attention-based approach, which only performs the semantic interaction between words, does not establish the syntactic relation interaction between aspect words and text words, resulting in the aspect words incorrectly focusing on information about words that are irrelevant to their syntax. In addition, the positional distance feature and the syntactic distance feature of words, which reflect their relationships in the linear form of the sentence and in the syntactic dependency tree of the sentence, respectively, are ignored by the method of processing syntactic information using graph convolutional networks, allowing irrelevant information far from the aspect words to interfere with their sentiment analysis. To address this problem, a Multi-Interaction Graph Convolutional Network (MIGCN) is proposed. First, the context words positional distance features are fed into each layer of the graph convolutional network, while the adjacency matrix of the graph convolutional network is weighted by using the syntactic

收稿日期：2021-05-25；改回日期：2021-09-07；网络出版：2021-09-17

*通信作者： 王汝言 wangry@cqupt.edu.cn

基金项目：国家自然科学基金(61901071, 61871062, 61771082)，重庆市高校创新团队建设计划(CXQT20017)，重庆市自然科学基金(cstc2019jcyj-zdxmX0024)

Foundation Items: The National Natural Science Foundation of China (61901071, 61871062, 61771082), The University Innovation Research Group Program of Chongqing (CXQT20017), The Natural Science Foundation of Chongqing (cstc2019jcyj-zdxmX0024)

distance of context words in the dependency tree. Finally, semantic interaction and syntactic interaction are designed to process the semantic and syntactic information between words, respectively. The experimental results show the proposed model can outperform state-of-the-art baselines on the available datasets.

Key words: Aspect-level sentiment analysis; Graph convolutional network; Dependency tree; Attention mechanisms

1 引言

情感分析，又称意见挖掘，是对主观性文本中关于某个实体的观点、情感、情绪及态度的计算研究。而基于方面的情感分析主要任务是建模方面词和句子文本词之间的联系，从而识别句子中特定方面的情感极性(例如，消极、中性或积极)。如图1所示，给定句子中包含两个方面“food”和“service”，所对应的情感极性分别是积极和消极。

传统的基于机器学习的方法依赖于构建特征工程的质量[1]。Tang等人[2]利用长短期记忆网络(Long Short-Term Memory, LSTM)从方面和句子文本中取得句子级的特征信息，从而获得情感极性。Ma等人[3]在LSTM的基础上，引入注意力机制，将句子与方面词的隐藏特征进行交互。Fan等人[4]使用两种不同粒度的注意力机制来捕获方面词与句子之间的交互信息。这些传统通过注意力机制方法，使用方面词嵌入向量和句子中各文本词嵌入向量分别做内积运算，得到向量之间的空间距离，代表单词之间的语义相似性，从而进行方面词与文本词之间的语义交互。然而，仅从语义角度将文本词与方面词之间进行交互，未考虑单词之间的语法依存关系，注意力机制会错误的关注与方面词语法上不相关的情感意见词，尤其在句子中包含极性相反的多个情感意见词时，若不能正确区分方面词所对应的情感意见词，则会导致模型做出错误的判断。如图2所示，给定一个句子，基于注意力机制的模型仅关注单词之间的语义相似度，由于“cooked”和“fine”两个形容词经常可与名词“chicken”搭配，因此它们对应的词嵌入向量与“chicken”嵌入向量之间空间距离十分相近，仅依靠向量空间距离的单一语义交互无法区分方面词“chicken”所对应的情感意见词是“cooked”还是“fine”。结合语法依存树，引入单词之间的语法关系进行交互，可使方面词根据语法依存关系正确关注到其对应的情感意见词。根据单词之间语法依存信息，方面词“chicken”通过依存关系“nsubj”和“acomp”关注到相应的情感意见词“fine”，同样，方面词“falafel”通过相应的依存关系关注到情感意见词“cooked”。因此，引入单词之间的语法交互是有必要的。近年来，由于图卷积网络(Graph Convolutional Networks, GCN)[5]能够处理句子语法依存树这种非结构化数据的能力，其被应用到方面情感分析中。Zhang等人[6]利用句子中的依存关系来构建图卷积网络的邻接矩阵，但没有体现单词距离特征信息。Huang等人[7]利用图卷积网络的一种变体形式识别方面所对应的情感极性，但忽略了文本词在依存树中的语法距离信息。位置距离[8]和语法距离[8]可以分别体现方面词与各文本词在句子线性形式中和句子语法依存树中的相对位置关系，并且关注方面词距离较近文本词的本地信息对情感分析有利[9]，因此，如何将这些距离特征馈入图卷积网络中是一个问题。

针对上述问题，本文提出多交互图卷积网络(Multi-Interaction Graph Convolutional Networks, MIGCN)。首先，将各文本词在句子线性形式中的位置距离特征馈入到每层图卷积网络中，同时根据文本词在依存树中的语法距离特征对图卷积网络的邻接矩阵进行加权，最后，设计语义交互和语法交互，同时获取单词之间的语义信息和语法依存信息之后融合。

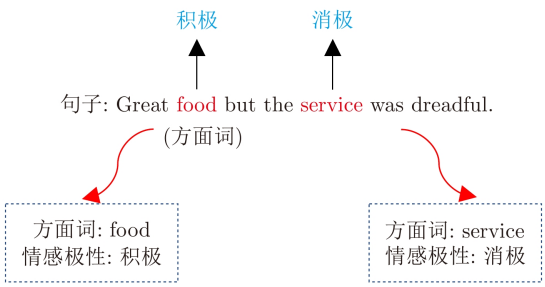


图 1 方面情感分析任务样例

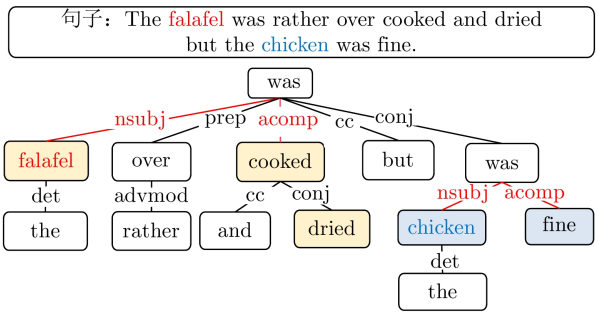


图 2 包含相反极性方面词的句子依存树

2　相关工作

情感分析旨在识别文本的情感极性，而方面级情感分析是情感分析中的一项子任务，其目标是识别句子中一个特定方面的情感极性。经典的神经网络模型主要是利用循环神经网络、卷积神经网络等变体模型来对文本进行建模。Tang等人[2]提出了基于目标依存的长短期记忆网络 (Target-Dependent Long Short-Term Memory, TD-LSTM)模型，使用了两个LSTM从两个不同的方向分别对方面词的左边和右边的文本建模，基于目标关联的长短期记忆网络 (Target-Connection Long Short-Term Memory, TC-LSTM)在TD-LSTM的基础上进一步加强了方面词与句子中每个词的关联。基于注意力机制的方法可以使模型在训练过程中高度关注特定方面的特征信息，有效识别不同方面和句子中词语的相互关系，挖掘更多的隐藏特征，取得更好的情感识别效果。Ma等人[3]首次让句子与方面词进行交互式学习，提出交互式注意神经网络 (Interactive Attention Networks, IAN)模型，分别对方面词和句子进行注意操作。此外,使用多头注意机制可进一步对文本和方面词建模和进行交互处理，获得句子和方面词的隐藏特征信息。近年来，基于语法特征的语言模型最近受到广泛关注，由于GCN在处理非结构化数据的优势，其被应用到方面情感分析任务中。Zhang等人[6]使用句法依存树获取句子中的语法依赖信息，并使用图卷积网络对文本进行建模，从而识别方面所对应的情感极性。Sun等人[10]利用双向长短期记忆网络 (Bi-directional Long Short-Term Memory, Bi-LSTM)来学习句子表示，并使用结合依存树的图卷积网络模型增强句子表示。Bai等人[11]在图注意网络模型的基础上利用标签特征，考虑邻接矩阵与依存关系的对应关系。

3　提出模型

给定一个长度为 n 的句子$s=\{w_1,w_2,\cdots,w_n\}$和长度为m的方面$a=\{w_{t+1},w_{t+2},\cdots,w_{t+m}\}$，即方面词$a$是句子$s$的一个子序列。本文框架如图3所示，由6部分组成，分别是嵌入层、隐藏层、图卷积网络层、方面特定遮掩层、多交互注意层以及输出层。其中，图卷积网络层分为位置编码和加权图卷积网络两部分，分别融入文本词位置距离特征和语法距离特征；多交互注意层设计语义交互和语法交互；最后，输出层门控进行特征融合。

3.1　嵌入层与隐藏层

嵌入层是将每个词或词语通过嵌入矩阵映射到向量空间中。本文采用GloVe嵌入获得每个词向量，通过嵌入矩阵获取每个词向量$\boldsymbol{w}^i\in\boldsymbol{R}^{|V|}$。通过

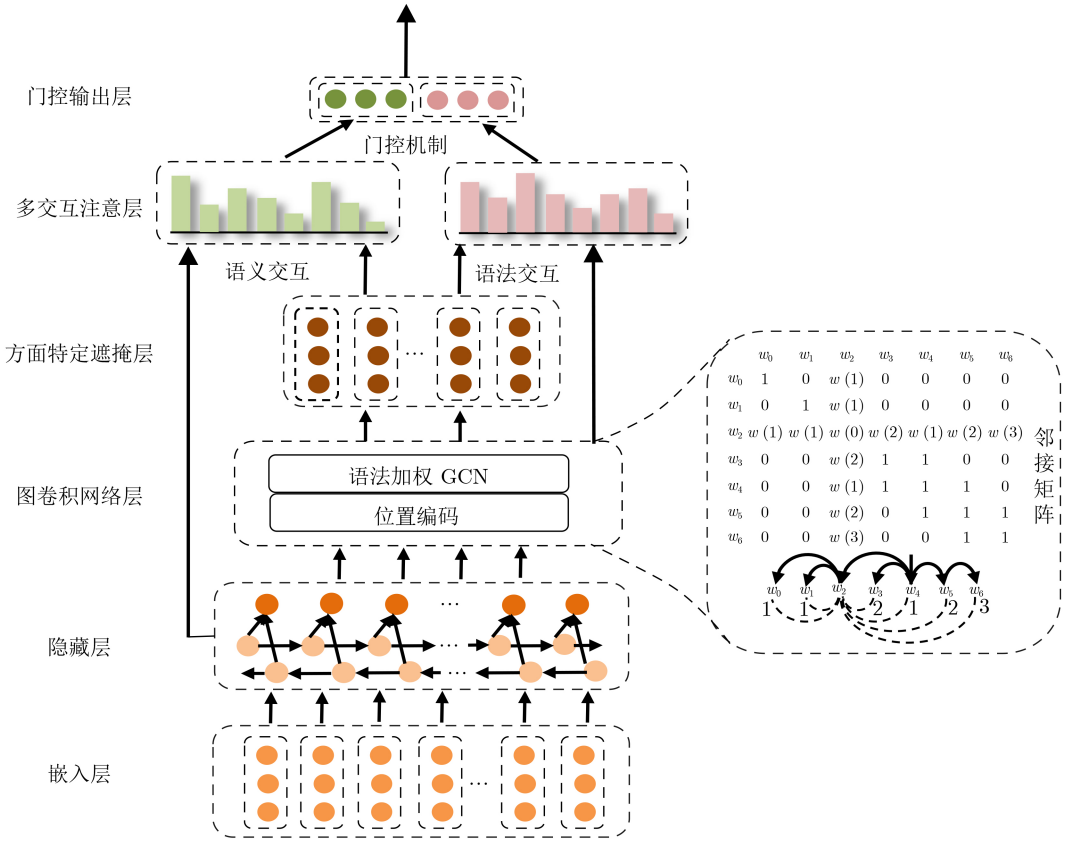


图 3 MIGCN模型框架

Bi-LSTM学习句子中单词隐藏信息。将经过前向LSTM输出$\boldsymbol{h}_{\mathrm{F}}$与后向LSTM输出$\boldsymbol{h}_{\mathrm{B}}$拼接，得到隐藏层最终输出结果$\boldsymbol{h}_{\mathrm{s}}=[\boldsymbol{h}_{\mathrm{F}};\boldsymbol{h}_{\mathrm{B}}]$。

3.2 图卷积网络层

图卷积网络层主要由两部分组成，分别是位置编码和加权图卷积网络。在位置编码部分，结合各文本单词在句子线性形式中的位置距离特征，计算不同文本单词的权重，融合到每层网络的输出向量中。在加权图卷积网络部分，利用文本词在句子语法依存树中的语法距离特征，对图卷积网络的邻接矩阵进行加权。

3.2.1 位置编码

结合文本词在句子线性形式中的位置距离特征，增强距离方面词较近单词的本地信息，削弱距离方面词较远单词的信息。例如，在句子“Great **food** but the **service** was dreadful!”中，距方面词“food”较近的单词“Great”，更能表达对应的情感信息。利用位置距离特征对句子中各文本词计算相应权重，并将其融入到每层网络输出向量中，如式(1)、式(2)所示

$$p_i=\begin{cases}1-(j_s-i)/n, & 0\le i<j_s\\ 0, & j_s\le i<j_{s+m}\\ 1-(i-j_{s+m})/n, & j_{s+m}\le i\le n\end{cases}\tag{1}$$

$$\boldsymbol{h}_p=F(\boldsymbol{h}_s)=p_i\cdot\boldsymbol{h}_s\tag{2}$$

其中，p_i是第i个词位置权重，j_s和j_{s+m}分别是方面词开始索引和结束索引，F是位置权重函数。

3.2.2 加权图卷积网络

对于图$\boldsymbol{G}=\{\boldsymbol{V},\boldsymbol{A}\}$, $\boldsymbol{A}\in\boldsymbol{R}^{n\times n}$是节点之间的邻接矩阵。若节点$v_i$与$v_j$有语法依存关系，则其对应邻接矩阵$\boldsymbol{A}_{ij}=1$。将节点$v_i$第$l$层输出记$\boldsymbol{h}_i^l$，则$L$层GCN输出为$\boldsymbol{h}_i^L$，如式(3)所示

$$\boldsymbol{h}_i^l=\mathrm{RELU}\left(\sum_{j=1}^{n}\boldsymbol{A}_{ij}\boldsymbol{h}_j^{l-1}\boldsymbol{W}^l+b^l\right)\tag{3}$$

其中，$\boldsymbol{h}_j^{l-1}$表示GCN上一层节点v_j的嵌入向量，$\boldsymbol{W}^l$和b^l是权重矩阵和偏置项。

现有研究基于句子依存树作为图结构，并未考虑文本单词的语法距离特征，而语法距离特征已被证实对方面情感分析是有利的[8]。Zhou等人[12]利用单词之间的语义相似度，即单词嵌入向量之间的空间距离对图卷积网络的邻接矩阵进行加权，而本文结合依存树中语法依存关系构建邻接矩阵，设计一种基于语法距离特征的加权图卷积网络。在实验中，语法距离(Syntactic Distance, SD)是指输入文本词到方面词在句子语法依存树上的最短距离。如图4所示，依存树中SD(amplifier, loudly)=2, SD(sound, loudly)=3, SD(sound amplifier, loudly)=2.5，语法距离加权邻接矩阵由算法1得到，如表1所示。

权重函数为衡量计算输入词到方面词的权重系数，与位置权重类似，距离越近，权重系数值越大。在提出的模型中，利用式(4)来计算语法权重系数

$$\mathrm{Weight}(d)=\frac{1}{\mathrm{e}^{d-1}}\tag{4}$$

其中，d是语法距离，因此经过加权图卷积网络之后的输出如式(5)所示

$$\boldsymbol{h}_i^l=\sigma\left(\frac{\sum_{j=1}^{n}\boldsymbol{A}'_{ij}\boldsymbol{g}_j^{l-1}\boldsymbol{W}^l}{d_i+1}+b^l\right)\tag{5}$$

其中，$\boldsymbol{A}'_{ij}$是通过语法加权构建的邻接矩阵，$d_i=\sum_{j=1}^{n}\boldsymbol{A}'_{ij}$是单词节点的度，$\boldsymbol{h}_i^l$是当前卷积网络输出结果，$\boldsymbol{g}_i^l$是前一层图卷积网络的输出结果。每层网络的输出均通过位置编码加权，降低依存树中噪声信息，L层加权图卷积网络层最终输出如式(6)、式(7)所示

$$\boldsymbol{g}_i^l=F(\boldsymbol{h}_i^l)\tag{6}$$

$$\boldsymbol{h}^L=\{\boldsymbol{h}_1^L,\boldsymbol{h}_2^L,\cdots,\boldsymbol{h}_n^L\}\tag{7}$$

3.3 方面特定遮掩层

对L层图卷积网络层的输出进行遮掩，保留方面词向量，如式(8)所示，方面词所对应的位置设置为1，非方面词对应位置为0，经过方面特定遮掩层后的输出$\boldsymbol{h}_i^{L_{\mathrm{mask}}}$如式(9)所示

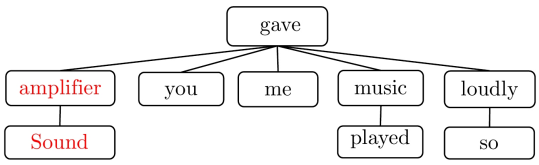


图 4 方面为短语的依存树样例

表 1 基于语法加权的邻接矩阵算法(算法1)

输入：T：句子依存树；a：句子中方面词；N：句子序列长度；
输出：$\boldsymbol{A}$: 语法加权邻接矩阵；

(1) **初始化**$\boldsymbol{A}\in\boldsymbol{R}^{N\times N}$中所有元素为0;
(2) 从依存树T的根部遍历每个节点i:
(3) 设置矩阵的主对角线元素$A_{ii}=1$;
(4) 遍历根为节点i的子树中的所有节点j;
(5) 令$A_{ij}=1$和$A_{ji}=1$;
(6) 计算节点i与句子中方面词a的语法距离d;
(7) 令$A_{ia_i}=\mathrm{Weight}(d)$和$A_{a_ii}=\mathrm{Weight}(d)$。

$$\boldsymbol{M}_i^{\text{mask}} = \left[0, \cdots, \underbrace{1, \cdots 1}_{m}, \cdots, 0\right]^{\text{T}} \tag{8}$$

$$\boldsymbol{h}_i^{L_{\text{mask}}} = \boldsymbol{M}_i^{\text{mask}} \boldsymbol{h}_i^{L} \tag{9}$$

其中，$\boldsymbol{h}_i^{L_{\text{mask}}} = \left\{0, \cdots, \boldsymbol{h}_t^{L_{\text{mask}}}, \cdots, \boldsymbol{h}_{t+m}^{L_{\text{mask}}}, \cdots, 0\right\}$是包含句子语法信息和语义信息的方面词隐藏特征。

3.4 多交互注意层

为同时关注文本词与方面词之间语义关系和语法依存关系，设计语义和语法两个角度的多交互注意机制，同时提取语义和语法特征信息。

语义交互：经过Bi-LSTM之后获取文本中隐藏的语义特征的上下文$\boldsymbol{h}_s$，与方面特征遮掩之后的方面词$\boldsymbol{h}^{L_{\text{mask}}}$之间进行交互。如式(10)—式(12)所示

$$\text{Similarity}_{\text{se}}(\boldsymbol{h}_s, \boldsymbol{h}^{L_{\text{mask}}}) = \sum_{i=1}^{n} \boldsymbol{h}_{\text{s}}^{\text{T}} \boldsymbol{h}_i^{L_{\text{mask}}} \tag{10}$$

$$\alpha = \frac{\exp(\text{Similarity}_{\text{se}}(\boldsymbol{h}_s, \boldsymbol{h}^{L_{\text{mask}}}))}{\sum_{i=1}^{n} \exp(\text{Similarity}_{\text{se}}^{i}(\boldsymbol{h}_s, \boldsymbol{h}^{L_{\text{mask}}}))} \tag{11}$$

$$\boldsymbol{h}_{\text{se}} = \sum_{j=1}^{n} \alpha_j \boldsymbol{h}_s^j \tag{12}$$

语法交互：经过L层GCN之后获取文本中隐藏的语法特征的上下文$\boldsymbol{h}^L$，与方面特征遮掩之后的方面词$\boldsymbol{h}^{L_{\text{mask}}}$之间进行交互。如式(13)—式(15)所示

$$\text{Similarity}_{\text{sy}}(\boldsymbol{h}^L, \boldsymbol{h}^{L_{\text{mask}}}) = \sum_{i=1}^{n} (\boldsymbol{h}^L)^{\text{T}} \boldsymbol{h}_i{}^{L_{\text{mask}}} \tag{13}$$

$$\beta = \frac{\exp(\text{Similarity}_{\text{sy}}(\boldsymbol{h}^L, \boldsymbol{h}^{L_{\text{mask}}}))}{\sum_{i=1}^{n} \exp(\text{Similarity}_{\text{sy}}^{i}(\boldsymbol{h}^L, \boldsymbol{h}^{L_{\text{mask}}}))} \tag{14}$$

$$\boldsymbol{h}_{\text{sy}} = \sum_{j=1}^{n} \beta_j \boldsymbol{h}^L \tag{15}$$

将多交互层得到语法交互特征向量$\boldsymbol{h}_{\text{sy}}$和语义交互特征向量$\boldsymbol{h}_{\text{se}}$拼接，得到$\boldsymbol{h}_f = [\boldsymbol{h}_{\text{se}}; \boldsymbol{h}_{\text{sy}}]$。

3.5 输出层

为学习包含语义和语法特征的复合表示，使用门控机制实现特征融合。如式(16)所示，将语法特征表示$\boldsymbol{h}_{\text{sy}}$融合到语义特征表示$\boldsymbol{h}_{\text{se}}$中

$$\boldsymbol{h}_{\text{o}} = g \odot \boldsymbol{h}_{\text{sy}} + (1 - g) \odot \boldsymbol{h}_{\text{se}} \tag{16}$$

其中，$\odot$表示元素对应乘积操作，$g = \sigma(\boldsymbol{W}_g \boldsymbol{h}_f + b_g)$是门控系数，将经过门控机制的输出$\boldsymbol{h}_{\text{o}}$馈入到全连接层，并通过softmax分类器，如式(17)所示

$$\boldsymbol{y} = \text{softmax}(\boldsymbol{x} = \boldsymbol{W}_{\text{o}} \boldsymbol{h}_{\text{o}} + b_{\text{o}}) = \frac{\exp(x)}{\sum_{k=1}^{C} \exp(x)} \tag{17}$$

其中，$\boldsymbol{W}_{\text{o}} \in \boldsymbol{R}^{1 \times \text{C}}$和$\boldsymbol{b}_{\text{o}} \in \boldsymbol{R}^{\text{C}}$是模型参数。$C$为情感极性类别数，$\boldsymbol{y} \in \boldsymbol{R}^C$是预测情感极性分布。

4 实验

4.1 数据集

在5个数据集上进行实验：分别是ACL14 Twitter[13], SemEval 2014[14], SemEval 2015[15], SemEval 2016[16]评论集。如表2所示，给出数据集中训练集和测试集的实例数量。

4.2 参数设置

在实验中，使用嵌入维度为300的预训练GloVe作为初始词嵌入，Bi-LSTM的隐藏层维度设置为300，模型中的权重采用满足均匀分布进行初始化。使用Adam作为优化器，学习率设置为1×10^{-3}，L2正则项系数设置为1×10^{-5}，批量训练样本设置为32。

4.3 实验结果

如表3所示，在基于GCN的模型中，MIGCN相比于利用依存树并使用无向图构建邻接矩阵的ASGCN-DG模型，在5个数据集上准确率平均提升1.04 %，宏F1值平均提升2.24 %；与GCN的变体TD-GAT相比，准确率平均提升1.05 %，宏F1值平均提升2.80 %。在Twitter和Rest15数据集上，由于网络用户评论语句的语法结构较弱，而BiGCN使用双重图卷积网络关注单词共现信息，对英文中惯用表达更加敏感，因此在句子语法结构较弱的情况下，所提MIGCN模型取得次优效果。对于kumaGCN，其采用潜图结构，仅关注与方面词有直接语法依存关系个别文本单词信息，过滤掉

表 2　数据集的统计

数据集	积极		中性		消极	
	训练集	测试集	训练集	测试集	训练集	测试集
Lap14	994	341	464	169	870	128
Twitter	1561	173	3127	346	1560	173
Rest14	2164	728	637	196	807	196
Rest15	912	326	36	34	256	182
Rest16	1260	469	69	30	439	117

与其间接依存文本词语法信息，所以在Res15和Res16数据集上宏F1值高于MIGCN，但潜图结构会将一些重要的文本词语法信息过滤，进而导致其在Twitter和Lap14数据集上劣于MIGCN。

5 实验分析

5.1 消融实验

如表4所示，w/o se表示仅去掉语义交互，w/o sy表示仅去掉语法交互，w/o we表示没有使用语法距离加权构建图卷积网络中的邻接矩阵，w/o ga表示没有使用门控机制对语法交互和语义交互进行融合，w/o sy+ga代表利用门控机制融合未经语法交互的特征向量，w/o se+ga代表利用门控机制融合未经语义交互的特征向量。对比w/o se, w/o sy和基准模型，证明单一交互性能低于多交互性能。观察w/o we，验证语法距离加权后邻接矩阵可提升网络性能。同时，对比w/o sy+ga和w/o se+ga，在使用门控机制融合情况下，去掉任何一种交互方式，模型准确率和宏F1值均下降，进一步表明结合语法和语义多交互机制重要性。

5.2 GCN层数分析

实验将GCN层数分别设置为$L \in \{1,2,\cdots,12\}$，在5个数据集上的准确率和宏F1值分别如图5和图6所示。MIGCN在网络深度为2层时达到了最佳的性能，但随着网络深度的增加，模型在5个公共数据集上的性能随之下降。在网络深度为12层时，相比于最佳性能，准确率平均下降2.1%，宏F1值平均下降3.6%，由于引入更多参数，模型产生过拟合现象。

5.3 案例分析

实验从Rest14数据集中任取两个句子进行注意力可视化分析，第1行代表基于语法交互的注意力分数，第2行是基于语义交互注意力分数，区域颜色越深，代表注意权重越大。如图7所示，基于语义和语法的注意力机制均能分别判断出影响方面词“staff”情感极性的词为“should be a bit”，使MIGCN正确识别出方面所对应情感极性，证明语义交互和语法交互对情感分析均有利。如图8所示，无论基于语法注意力机制还是基于语义注意力机制，均正确识别影响方面词情感极性关键词为

表 3 不同模型结果对比(%)

类别	模型	Twitter		Lap14		Rest14		Rest15		Rest16	
		准确率	宏F1	准确率	宏F1	准确率	宏F1	准确率	宏F1	准确率	宏F1
基线	SVM	63.40	63.30	70.49	–	80.16	–	–	–	–	–
	LSTM[2]	69.56	67.70	69.28	63.09	78.13	67.47	77.37	55.17	86.80	63.88
交互模型	IAN[3]	72.50	70.81	72.05	67.38	79.26	70.09	78.54	52.65	84.74	55.21
	MGAN[4]	72.54	70.81	75.27	70.81	81.25	71.94	–	–	–	–
	AOA[17]	72.30	70.20	76.62	67.52	79.97	70.42	78.17	57.02	87.50	66.21
	AEN-GloVe[10]	72.83	69.81	73.51	69.04	80.98	72.14	–	–	–	–
GCN 模型	ASGCN [6]	72.15	70.40	75.55	71.05	80.77	72.02	79.89	61.89	88.99	67.48
	TD-GAT[7]	72.20	70.45	75.63	70.74	81.32	71.72	80.38	60.50	87.71	67.87
	BiGCN[18]	**74.16**	**73.35**	74.59	71.84	81.97	73.48	**81.16**	64.79	88.96	70.84
	kumaGCN[19]	72.45	70.77	76.12	72.42	81.43	73.64	80.69	**65.99**	89.39	**73.19**
本文模型	**MIGCN**	73.31	72.12	**76.59**	**72.44**	**82.32**	**74.31**	80.81	64.21	**89.50**	71.97

表 4 消融实验结果(%)

模型	Twitter		Lap14		Rest14		Rest15		Rest16	
	准确率	宏F1	准确率	宏F1	准确率	宏F1	准确率	宏F1	准确率	宏F1
MIGCN	**73.31**	**72.12**	**76.59**	**72.44**	**82.32**	**74.31**	**80.81**	**64.21**	**89.50**	**71.97**
w/o se	71.34	69.54	74.97	70.89	80.21	71.85	78..60	59.01	88.20	69.20
w/o sy	72.45	70.64	75.34	71.03	81.55	73.29	79.40	62.22	89.02	66.72
w/o we	72.88	70.88	76.49	72.28	81.73	73.64	79.95	64.00	88.58	71.12
w/o ga	72.93	71.45	75.91	71.85	81.85	73.53	79.52	63.92	88.58	68.98
w/o sy + ga	72.98	71.40	75.08	70.84	81.19	72.74	78.17	58.24	88.26	68.21
w/o se + ga	72.16	70.33	74.71	70.54	79.82	71.09	79.46	61.55	88.80	67.97

“Best”，说明同时关注单词语义信息和语法信息必要性。

6　结论

本文提出一种多交互图卷积网络，首先将位置距离特征馈入到每层图卷积网络中，同时利用语法距离特征对图卷积网络的邻接矩阵进行加权，最后设计多交互机制将语法和语义特征融合。实验结果表明，文本词的位置距离特征和语法距离特征均不可忽略，且在单词之间同时进行语义和语法交互是有利的，所提模型在公开数据集上准确率和F1值优于基准模型。

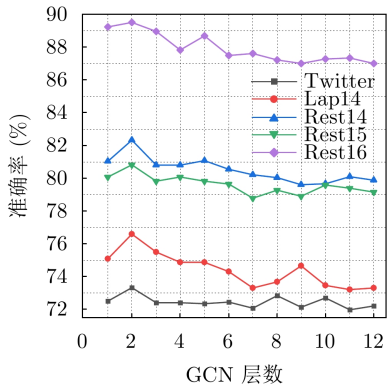


图 5 GCN网络深度与准确率的关系

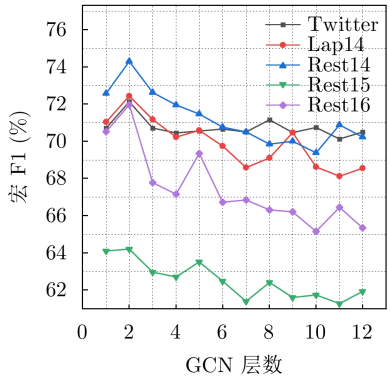


图 6 GCN网络深度与宏F1值的关系

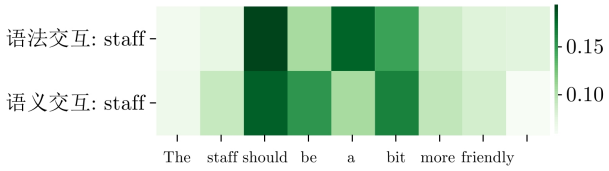


图 7 方面为单词“staff”的可视化结果



图 8 方面为短语“Indian food”的可视化结果

参 考 文 献

[1] JIANG Long, YU Mo, ZHOU Ming, *et al*. Target-dependent twitter sentiment classification[C]. The 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies, Portland, USA, 2011: 151–160.

[2] TANG Duyu, QIN Bing, FENG Xiaocheng, *et al*. Effective LSTMs for target-dependent sentiment classification[C]. The 26th International Conference on Computational Linguistics, Osaka, Japan, 2016: 3298–3307.

[3] MA Dehong, LI Sujian, ZHANG Xiaodong, *et al*. Interactive attention networks for aspect-level sentiment classification[C]. The 26th International Joint Conference on Artificial Intelligence, Melbourne, Australia, 2017: 4068–4074.

[4] FAN Feifan, FENG Yansong, and ZHAO Dongya Multi-grained attention network for aspect-level sentiment classification[C]. The 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Belgium, 2018: 3433–3442.

[5] KIPF T N and WELLING M. Semi-supervised classification with graph convolutional networks[C]. The 5th International Conference on Learning Representations, Toulon, France, 2017.

[6] ZHANG Chen, LI Qiuchi, and SONG Dawei. Aspect-based sentiment classification with aspect-specific graph convolutional networks[C]. The 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, Hong Kong, China, 2019: 4568–4578.

[7] HUANG Binxuan and CARLEY K M. Syntax-aware aspect level sentiment classification with graph attention networks[C]. The 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, Hong Kong, China, 2019: 5469–5477.

[8] PHAN M H and OGUNBONA P O. Modelling context and syntactical features for aspect-based sentiment analysis[C]. The 58th Annual Meeting of the Association for Computational Linguistics, Online, 2020: 3211–3220.

[9] XUE Wei and LI Tao. Aspect based sentiment analysis with gated convolutional networks[C]. The 56th Annual Meeting of the Association for Computational Linguistics, Melbourne, Australia, 2018: 2514–2523.

[10] SUN Kai, ZHANG Richong, MENSAH S, *et al*. Aspect-level sentiment analysis via convolution over dependency tree[C]. The 2019 Empirical Methods in Natural Language Processing and the 9th International Joint Conference on

Natural Language Processing, Hong Kong, China, 2019: 5679–5688.

[11] BAI Xuefeng, LIU Pengbo, and ZHANG Yue. Investigating typed syntactic dependencies for targeted sentiment classification using graph attention neural network[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2021, 29: 503–514. doi: 10.1109/TASLP.2020.3042009.

[12] ZHOU Li, WANG Tingyu, QU Hong, *et al*. A weighted GCN with logical adjacency matrix for relation extraction[C]. The 24th European Conference on Artificial Intelligence, Santiago de Compostela, Spain, 2020: 2314–2321.

[13] DONG Li, WEI Furu, TAN Chuanqi, *et al*. Adaptive recursive neural network for target-dependent twitter sentiment classification[C]. The 52nd Annual Meeting of the Association for Computational Linguistics, Baltimore, USA, 2014: 49–54.

[14] PONTIKI M, GALANIS D, PAVLOPOULOS J, *et al*. Semeval-2014 task 4: Aspect based sentiment analysis[C]. The 8th International Workshop on Semantic Evaluation, Dublin, Ireland, 2014: 27–35.

[15] PONTIKI M, GALANIS D, PAPAGEORGIOU H, *et al*. Semeval-2015 task 12: Aspect based sentiment analysis[C]. The 9th International Workshop on Semantic Evaluation, Denver, USA, 2015: 486–495.

[16] PONTIKI M, GALANIS D, PAPAGEORGIOU H, *et al*. Semeval-2016 task 5: Aspect based sentiment analysis[C]. The 8th International Workshop on Semantic Evaluation, San Diego, USA, 2016: 19–30.

[17] SONG Youwei, WANG Jiahai, JIANG Tao, *et al*. Targeted sentiment classification with attentional encoder network[C]. 28th International Conference on Artificial Neural Networks and Machine Learning, Munich, Germany, 2019: 93–103.

[18] ZHANG Mi and QIAN Tieyun. Convolution over hierarchical syntactic and lexical graphs for aspect level sentiment analysis[C]. The 2020 Conference on Empirical Methods in Natural Language Processing, Online, 2020: 3540–3549.

[19] CHEN Chenhua, TENG Zhiyang, and ZHANG Yue. Inducing target-specific latent structures for aspect sentiment classification[C]. The 2020 Conference on Empirical Methods in Natural Language Processing, Online, 2020: 5596–5607.

王汝言：男，1969年生，教授，研究方向为泛在网络，多媒体信息处理等.

陶中原：男，1996年生，硕士生，研究方向为自然语言处理，情感分析.

赵容剑：男，1998年生，硕士生，研究方向为自然语言处理，情感分析.

张普宁：男，1988年生，副教授，研究方向为物联网搜索等.

杨志刚：男，1981年生，博士，研究方向为安全隐私保护等.

责任编辑：余 蓉